

PRÁCTICA 3: Despliegue de un Clúster Real y Gestión de Recursos YARN

Objetivo: Desplegar un clúster distribuido de 3 nodos (1 Maestro, 2 Esclavos), ejecutar trabajos MapReduce y configurar colas de recursos en YARN.

Requisitos Previos

- 3 Máquinas Virtuales (Nodos) conectadas en red.
- Nombres de host configurados en /etc/hosts (ej: nodo1, nodo2, nodo3).
- SSH sin contraseña configurado entre el nodo maestro y los esclavos.

Parte 1: Configuración Distribuida (Archivos XML)

Realizar en el nodo maestro y replicar en los esclavos:

1. **core-site.xml:** Configura el fs.defaultFS apuntando al nodo maestro (ej: hdfs://nodo1:9000).
2. **yarn-site.xml:**
 - Define yarn.resourcemanager.hostname apuntando al nodo1.
 - Habilita los servicios auxiliares mapreduce_shuffle.
3. **hdfs-site.xml:** Configura las rutas de datos y el factor de replicación (ej: replicación a 2 si tienes 2 esclavos).
4. **workers:** Edita este archivo para listar los nombres de los nodos esclavos (ej: nodo2, nodo3).

Parte 2: Despliegue y Verificación

1. **Arranque del Clúster:**
 - Ejecuta start-dfs.sh y start-yarn.sh desde el nodo maestro.
 - (Opcional) Inicia el History Server: mapred daemon start historyserver.
2. **Validación de Procesos (JPS):**
 - **Nodo Maestro:** Debe correr ResourceManager, NameNode, SecondaryNameNode.
 - **Nodos Esclavos:** Deben correr NodeManager y DataNode.
3. **Interfaz Web:** Verifica en el navegador que los 3 nodos son reconocidos y están vivos.

Parte 3: Ejecución de Trabajos MapReduce

1. Crea un directorio en HDFS (ej: /prueba) y sube un archivo de texto grande (ej: logs).
2. Ejecuta el ejemplo **WordCount** incluido en los ejemplos de Hadoop contra ese archivo.

3. Observa el progreso del trabajo en la consola y verifica que finaliza con éxito ("Completed successfully").

Parte 4: Gestión Avanzada de YARN (Colas)

1. Comandos YARN:

- Lista los nodos activos usando `yarn node -list`.
- Lista las aplicaciones corriendo con `yarn application -list`.
- Prueba a matar una aplicación en ejecución usando `yarn application -kill [AppID]`.

2. Capacity Scheduler (Colas):

- Edita el archivo `capacity-scheduler.xml`.
- Define tres colas hijas bajo root: **default** (30%), **prod** (50%) y **desa** (20%).
- Refresca la configuración sin reiniciar el clúster: `yarn rmadmin -refreshQueues`.
- Verifica con `mapred queue -list` que las colas aparecen con sus capacidades asignadas.

3. Lanzamiento Específico:

- Lanza nuevamente el trabajo MapReduce, pero especifica la cola de destino (ej: **desa**) usando el parámetro `-Dmapreduce.job.queueName=desa`.

Entregable para los alumnos (Práctica 3): Un informe PDF que incluya capturas de:

1. El comando `jps` en los 3 nodos.
2. La salida del comando `yarn node -list` mostrando los nodos conectados.
3. El archivo `capacity-scheduler.xml` modificado.
4. La consola mostrando la ejecución exitosa del job MapReduce lanzado específicamente contra la cola "desa".