

Práctica de Laboratorio: Gestión Avanzada de Datos con Hive

Objetivo: Comprender la diferencia entre tablas gestionadas (Internas) y Externas, y aprender a manipular tipos de datos complejos (ARRAY, STRUCT, MAP) utilizados en entornos Big Data reales.

Requisitos: Tener el clúster Hadoop (HDFS + YARN) y Hive activos.

FASE 1: Preparación del Dataset (Ingeniería de Datos)

En Big Data, los datos rara vez vienen en un CSV limpio. A menudo vienen anidados. Vamos a crear un fichero que simula un registro de empleados con sus habilidades y departamentos.

Instrucciones para el alumno:

1. Abre una terminal de Linux (no entres a Hive todavía).
2. Crea el fichero de datos crudos en tu directorio de usuario.

Bash

```
cd /home/manu
```

```
nano empleados_data.txt
```

Contenido del fichero (Copiar y Pegar): *Nota: Estamos usando | como separador de columnas, , para listas y : para mapas clave-valor, tal como indica el esquema del curso.*

Plaintext

Michael|Montreal,Toronto|Male,30|DB:80|Product:Developer,Lead

Will|Montreal|Male,35|Perl:85|Product:Lead,Test:Lead

Shelley|New York|Female,27|Python:80|Test:Lead,COE:Architect

Lucy|Vancouver|Female,57|Sales:89,HR:94|Sales:Lead

(Guardar con Ctrl + O y Salir con Ctrl + X)

FASE 2: Tablas Internas y Datos Complejos

Vamos a crear una **Tabla Interna**. Hive controlará estos datos. Si borramos la tabla, Hive borrará los datos. Usaremos el esquema avanzado del PDF proporcionado .

1. Crear la Base de Datos y la Tabla Entra en Hive (hive) y ejecuta:

SQL

-- Crear una base de datos propia para la práctica

```
CREATE DATABASE IF NOT EXISTS curso_bigdata;
```

```
USE curso_bigdata;
```

```
-- Crear la tabla con estructura compleja
```

```
CREATE TABLE empleados_internal (  
    name STRING,  
    work_place ARRAY<STRING>,  
    sex_age STRUCT<sex:STRING, age:INT>,  
    skills_score MAP<STRING, INT>,  
    depart_title MAP<STRING, ARRAY<STRING>>  
)
```

```
COMMENT 'Tabla interna con datos complejos'
```

```
ROW FORMAT DELIMITED
```

```
FIELDS TERMINATED BY '|'
```

```
COLLECTION ITEMS TERMINATED BY ','
```

```
MAP KEYS TERMINATED BY ':';
```

2. Cargar los datos (Desde Linux) Usaremos LOAD DATA LOCAL porque el fichero está en nuestro sistema operativo.

```
SQL
```

```
LOAD DATA LOCAL INPATH '/home/manu/empleados_data.txt'
```

```
OVERWRITE INTO TABLE empleados_internal;
```

3. Consultas Avanzadas (SQL sobre Datos Complejos) Aquí es donde el alumno ve la potencia de Hive. No es un simple SELECT *.

- **Ver todo:**

```
SQL
```

```
SELECT * FROM empleados_internal;
```

- **Acceder a un Array (Lugares de trabajo):** *Extraer solo la primera ciudad de trabajo de cada empleado.*

```
SQL
```

```
SELECT name, work_place[0] as ciudad_principal FROM empleados_internal;
```

- **Acceder a una Struct (Edad):** *Usar la notación "punto" para entrar en la estructura.*

```
SQL
```

```
SELECT name, sex_age.age FROM empleados_internal WHERE sex_age.age > 30;
```

- **Acceder a un Mapa (Habilidad específica):** *Buscar la puntuación en "DB" (Base de datos).*

SQL

```
SELECT name, skills_score['DB'] as nota_db FROM empleados_internal;
```

FASE 3: Tablas Externas (Simulación Real)

En una empresa real, los datos suelen dejarse en una carpeta de HDFS compartida y Hive solo los "lee" sin ser el dueño.

1. Preparar el entorno en HDFS Sal de Hive (exit;) o abre otra terminal. Vamos a subir el fichero manualmente a HDFS, simulando que otro departamento lo ha dejado ahí.

Bash

Crear un directorio en HDFS para RRHH

```
hdfs dfs -mkdir -p /empresa/rrhh/datos
```

Subir el fichero

```
hdfs dfs -put /home/manu/empleados_data.txt /empresa/rrhh/datos/
```

Verificar que está ahí

```
hdfs dfs -ls /empresa/rrhh/datos/
```

2. Crear la Tabla Externa Vuelve a Hive. Vamos a crear la tabla apuntando a esa carpeta. Fíjate en EXTERNAL y LOCATION .

SQL

```
USE curso_bigdata;
```

```
CREATE EXTERNAL TABLE empleados_external (
  name STRING,
  work_place ARRAY<STRING>,
  sex_age STRUCT<sex:STRING, age:INT>,
  skills_score MAP<STRING, INT>,
  depart_title MAP<STRING, ARRAY<STRING>>
)
ROW FORMAT DELIMITED
```

FIELDS TERMINATED BY '|'

COLLECTION ITEMS TERMINATED BY ','

MAP KEYS TERMINATED BY ':'

LOCATION '/empresa/rrhh/datos';

3. Comprobación inmediata *Pregunta al alumno: ¿Hace falta ejecutar un LOAD DATA? Respuesta: NO. Como hemos dicho que la LOCATION es /empresa/rrhh/datos, Hive lee automáticamente lo que subimos en el paso 1.*

SQL

```
SELECT * FROM empleados_external;
```

FASE 4: El "Crash Test" (Ciclo de Vida)

Vamos a demostrar la diferencia fundamental de seguridad entre ambos tipos de tablas.

1. Borrar la Tabla Interna

SQL

```
DROP TABLE empleados_internal;
```

- **Acción:** Ve a la terminal y busca los datos en la ruta por defecto (/user/hive/warehouse/...).
- **Resultado: ¡Desaparecidos!** Hive ha borrado el fichero.

2. Borrar la Tabla Externa

SQL

```
DROP TABLE empleados_external;
```

- **Acción:** Ve a la terminal y comprueba si el fichero original sigue existiendo.

Bash

```
hdfs dfs -ls /empresa/rrhh/datos/
```

- **Resultado: ¡El fichero sigue ahí!** Hive solo borró el enlace (metadatos), pero los datos están a salvo.

Resumen Visual para el Alumno

Concepto	Tabla Interna (Managed)	Tabla Externa
Creación	CREATE TABLE	CREATE EXTERNAL TABLE

Concepto	Tabla Interna (Managed)	Tabla Externa
Datos	Propiedad de Hive	Propiedad externa (HDFS)
Ubicación	/user/hive/warehouse (Default)	LOCATION '/ruta/propia'
DROP TABLE	Borra datos y metadatos	Borra solo metadatos