


APACHE HIVE

GUÍA PRÁCTICA DE BIG DATA




MANUAL DE INSTALACIÓN, CONFIGURACIÓN Y GESTIÓN DE DATOS COMPLEJOS

```
CREATE TABLE IF NOT EXISTS hive_data (  
  id INT,  
  name STRING,  
  timestamp BIGINT  
)  
COMMENT 'Main data table'  
PARTITIONED BY (date STRING)  
STORED AS ORC;
```

```
<property>  
  <name>hive.exec.oode.local.auto</name>  
  <value>true</value>  
  <description>Enable local mode auto</description>  
</property>
```


¿QUÉ ES REALMENTE HIVE?


LA PIEL (User View)



SQL (HiveQL)

Interfaz amigable.
Definición lógica.

EL MÚSCULO (System View)



MapReduce / HDFS

Motor de procesamiento.
Almacenamiento distribuido.

Hive es el puente.

No es una base de datos
relacional.

Traduce consultas en
trabajos de MapReduce.

FASE 1: PREPARACIÓN DEL TERRENO (HDFS)

```
$ hdfs dfs -mkdir /tmp
$ hdfs dfs -mkdir /tmp
$ hdfs dfs -mkdir -p /user/hive/warehouse

$ hdfs dfs -chmod g+w /tmp
$ hdfs dfs -chmod g+w /user/hive/warehouse
```

Rutas Críticas:

- /tmp: Espacio para operaciones temporales.
- /user/hive/warehouse: Almacén físico predeterminado.

¡ATENCIÓN!

El permiso 'chmod g+w' (escritura para grupo) es obligatorio. Sin esto, la inicialización fallará.

FASE 2: INSTALACIÓN Y ENTORNO

1. Descomprimir



Ruta objetivo:
/opt/hadoop/hive

2. Variables .bashrc

```
export HIVE_HOME=/opt/hadoop/hive  
export PATH=$PATH:$HIVE_HOME/bin
```

3. Enlace Hadoop (hive-env.sh)

Renombrar:
hive-env.sh.template ->
hive-env.sh

```
export HADOOP_HOME=/opt/hadoop
```


FASE 3: CONFIGURACIÓN DEL SITIO

Archivo: hive-site.xml

Acción Crítica: Copiar
plantilla y editar
propiedades.

```
cp hive-default.xml.template  
hive-site.xml
```

```
<property>  
  <name>system:java.io.tmpdir</name>  
  <value>/tmp/hive/java</value>  
</property>  
  
<property>  
  <name>system:user.name</name>  
  <value>${user.name}</value>  
</property>
```

Evita
conflictos de
escritura y
usuario en
laboratorios
locales.

FASE 4: INICIALIZACIÓN DEL METASTORE

El Metastore es la 'memoria' de Hive (Derby DB). Debe inicializarse antes del primer uso.

```
$ schematool -dbType derby -initSchema
... usage: schemaTool ...
Metastore connection URL: jdbc:derby;;databaseName=metastore_db;create=true
Initialization script completed
schemaTool completed
```


Validación:

```
$ hive
hive> show databases;
```


PRIMERA INTERACCIÓN: TABLAS BÁSICAS

Entrada:

```
hive> create database ejemplo;  
hive> use ejemplo;  
hive> create table t1 (name string);  
hive> insert into t1 values ('mi nombre'  
);
```



The screenshot shows a web browser window with the address bar displaying `/user/hive/warehouse/ejemplo.db`. The main content area displays a table with the following columns: Permission, Owner, Group, Size, Last Modified, Replication, Block Size, and Name. The table contains one row with the following values: drwxr-xr-x, hive, hive, 0, 2021/19 17:30, 1, 22MB, and t1. The table name 't1' is highlighted with a blue box.

Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name
drwxr-xr-x	hive	hive	0	2021/19 17:30	1	22MB	t1

Observación: La sentencia INSERT lanzará un Job de MapReduce. Hive traduce SQL a tareas de ejecución.

INGENIERÍA DE DATOS: ESTRUCTURAS COMPLEJAS

Anatomía del dataset 'empleados.txt'

Michael|Montreal,Toronto|Male,30|DB:80|Product:Developer,Lead

PIPE: Separador de Columnas

COMA: Separador de Arrays (Colecciones)

DOS PUNTOS: Separador de Maps (Clave:Valor)

Action Item: Crear fichero local en /home/manu/empleados_data.txt

TABLAS INTERNAS (MANAGED TABLES)

Definición (Mapping)


```
CREATE TABLE empleados_internal (  
  name STRING,  
  work_place ARRAY<STRING>,  
  sex_age STRUCT<sex:STRING, age:INT>,  
  skills_score MAP<STRING, INT>,  
  depart_title MAP<STRING, ARRAY<STRING>>  
)  
ROW FORMAT DELIMITED  
FIELDS TERMINATED BY '|'   
COLLECTION ITEMS TERMINATED BY ','  
MAP KEYS TERMINATED BY ':';
```

Carga

```
LOAD DATA LOCAL INPATH '/home/manu/empleados_data.txt'  
OVERWRITE INTO TABLE empleados_internal;
```


CONSULTAS AVANZADAS

Extracción de datos en estructuras anidadas

ARRAY (Lista) 

```
SELECT work_place[0]  
FROM empleados_internal;
```

Accessing index 0
of the list.

STRUCT (Objeto)

```
SELECT sex_age.age  
FROM empleados_internal;
```

Dot notation for fields.

MAP (Clave-Valor)

```
SELECT skills_score['DB']  
FROM empleados_internal;
```

Bracket notation
for keys.

Output sample

```
{'DB':80} | {'Perl':85}
```


TABLAS EXTERNAS: EL ESTÁNDAR EMPRESARIAL

📄 **Concepto:** En producción, los datos existen independientemente de Hive. Hive solo los "lee".


📄 Simulación en HDFS (Terminal Linux)

1. Crear directorio empresarial

```
$ hdfs dfs -mkdir -p /empresa/rrhh/datos
```

2. Subir fichero manualmente

```
$ hdfs dfs -put empleados_data.txt  
/empresa/rrhh/datos/
```



DEFINICIÓN DE TABLA EXTERNA

```
CREATE EXTERNAL TABLE empleados_external (  
  name STRING,  
  work_place ARRAY<<STRING>,  
  sex_age STRUCT<sex:STRING, age:INT>,  
  ...  
)  
ROW FORMAT DELIMITED...  
LOCATION '/empresa/rrhh/datos';
```

Nota: No se ejecuta LOAD DATA. Hive lee automáticamente la ubicación especificada.

EL 'CRASH TEST': INTERNA VS EXTERNA

¿Qué ocurre al ejecutar DROP TABLE?

TABLA INTERNA

```
$ DROP TABLE empleados_internal;
```

Result: DESTRUCCIÓN TOTAL

- Metadatos (Schema): Borrados
- Datos en HDFS: BORRADOS

TABLA EXTERNA

```
$ DROP TABLE empleados_external;
```

Result: DATOS SEGUROS

- Metadatos (Schema): Borrados
- Datos en HDFS: INTACTOS
(/empresa/rrhh/datos)

RESOLUCIÓN DE PROBLEMAS COMUNES

⚠ Warnings SLF4J

Mensaje: "Class path contains multiple SLF4J bindings".

Acción: **IGNORAR**. Son librerías duplicadas inofensivas.

⚠ Error de Metastore

Síntoma: Hive no arranca o falla al crear tablas.

Solución: Borrar directorio 'metastore_db' y ejecutar '`schematool -initSchema`'.

⚠ Permission Denied

Síntoma: Error al escribir en /tmp o /warehouse.

Solución: Verificar '`chmod g+w`' en HDFS.

CHEATSHEET: COMANDOS ESENCIALES

SISTEMA

```
schematool -dbType derby  
-initSchema
```

```
hive (shell)
```

HDFS

```
hdfs dfs -ls /ruta
```

```
hdfs dfs -mkdir -p /ruta
```

```
hdfs dfs -put local remoto
```

HIVEQL (DDL/DML)

```
CREATE DATABASE nombre;
```

```
USE nombre;
```

```
CREATE TABLE ... ROW FORMAT  
DELIMITED ...;
```

```
LOAD DATA LOCAL INPATH ... INTO  
TABLE ...;
```

```
CREATE EXTERNAL TABLE ...  
LOCATION ...;
```

```
DROP TABLE nombre;
```