

Práctica de Laboratorio: Análisis de Deslizamientos Mundiales (NASA Dataset)

Introducción y Objetivos

En esta práctica realizaremos un ejercicio basado en un escenario real. Utilizaremos un dataset de la NASA que registra los deslizamientos de tierra ocurridos en los últimos años a nivel mundial. Aunque el dataset cuenta con unas 9.500 filas, la metodología de trabajo es la misma que si tuviéramos cientos de millones de registros.

Objetivos:

1. Conectar de forma remota mediante Beeline.
2. Crear e ingestar datos en Hive.
3. Realizar análisis descriptivos y agrupaciones complejas.
4. Unir tablas mediante Joins.
5. Exportar resultados para visualización en herramientas externas (Excel).

Fase 1: Conexión Remota y Preparación

Trabajaremos desde el Nodo 3 para conectarnos al servidor Hive alojado en el Nodo 1.

1. Iniciar Beeline: Ejecuta el cliente Beeline en tu terminal.
2. Conexión JDBC: Conéctate directamente a la base de datos de trabajo (ej. ejemplo) para ahorrar pasos posteriores:

```
!connect jdbc:hive2://nodo1:10000/ejemplo
```

3. **Verificación:** Comprueba si existen tablas previas:

```
SHOW TABLES;
```

Fase 2: Ingesta de Datos (ETL)

Definiremos la estructura de la tabla principal y cargaremos el archivo CSV proporcionado por la NASA.

1. Creación de la tabla deslizamientos: Define las columnas principales (ID, fecha, hora, país, tipo, víctimas, etc.):
2. Carga de datos: Importa el fichero desde el directorio temporal local:

Fase 3: Análisis de Datos (Analytics)

Ejecutaremos consultas SQL que Hive traducirá internamente a procesos MapReduce.

1. Conteo total: Verifica que se han cargado las aproximadamente 9.500 filas:
2. Filtros de Catástrofes: Localiza los países y fechas donde hubo más de 100 víctimas mortales:
3. Agrupación por Tipo: ¿Cuántos corrimientos ha habido de cada categoría?:
4. Ranking de Países: Identifica los 10 países con más deslizamientos registrados:

Fase 4: Operaciones de Join

Cruzaremos la tabla de deslizamientos con una tabla de códigos de países para enriquecer la información.

1. Crear tabla de apoyo países:
2. Cargar country.csv:
3. Consulta Multitabla: Obtén el código del país, nombre, motivo y cantidad de incidentes:

Fase 5: Ciclo de Vida del Dato (Exportación)

Big Data es un entorno de procesamiento; a menudo la información generada se lleva a otros sitios para su gestión final.

1. Exportar a local: Guarda el resultado de la consulta anterior en un directorio del servidor en formato CSV:
2. Tratamiento Externo:
 - Descarga el fichero generado (usualmente llamado 000000_0) a tu PC mediante FTP o FileZilla.
 - Abre el archivo en Excel y realiza la limpieza final (cabeceras como "Código", "Nombre", "Motivo", "Veces").
 - Visualización: Crea un gráfico de barras o una tabla dinámica para mostrar los motivos de los deslizamientos a tu cliente o jefe.

Conclusión para el Alumno

Hemos completado el ciclo de vida del dato en un entorno Big Data: desde la descarga de un dataset de la NASA, su ingesta y procesamiento en un clúster distribuido, hasta su transformación en un informe visual en Excel. Este flujo es el estándar en la industria para convertir datos masivos en información útil para la toma de decisiones.