

Práctica: Configuración de Acceso Remoto con HiveServer2 y Beeline

Introducción

Hasta ahora hemos trabajado con el cliente de Hive en modo local. Sin embargo, en un entorno real de Big Data, lo más razonable es trabajar de forma remota. Para ello, utilizaremos HiveServer2, un servidor basado en Apache Thrift que permite conexiones remotas a través de protocolos como JDBC y HTTP.

Fase 1: Configuración de Seguridad (Nodo 1)

Antes de arrancar el servidor, debemos ajustar la configuración para permitir conexiones sin errores de credenciales, dado que no estamos utilizando Kerberos en este módulo.

1. Dirígete al directorio de configuración: `/opt/hadoop/hive/conf/`.
2. Edita el archivo `hive-site.xml`.
3. Busca y modifica la siguiente propiedad:
 - Propiedad: `hive.server2.enable.doAs`.
 - Valor: `false`.
 - ¿Por qué?: Al ponerlo en `false`, permitimos entrar al servidor con el usuario que lo ejecutó (ej. `hadoop`) sin necesidad de validaciones de seguridad complejas que quedan fuera del propósito de esta sección.

Fase 2: Ejecución de HiveServer2 (Background)

Para mantener el servidor activo y que no bloquee nuestra terminal, lo lanzaremos en modo *background*.

1. Sitúate en el directorio donde se encuentran los metadatos (ej. el directorio BBDD creado previamente).
2. Ejecuta el comando: `hiveserver2 &`.
3. Verificación: Comprueba que el proceso Java está corriendo correctamente con el comando: `ps -ef | grep hiveserver2`. *Deberías ver un mensaje indicando "Starting HiveServer2"*.

Fase 3: Conexión local con Beeline

Beeline es la herramienta de línea de comandos que utiliza JDBC para conectarse al servidor.

1. Arranca el cliente escribiendo: `beeline`.
2. Usa el comando de conexión con la URL JDBC: `!connect jdbc:hive2://nodo1:10000`.

- Puerto: Por defecto es el 10.000.
- Credenciales: Cuando pida usuario y contraseña, puedes pulsar Enter para entrar con los valores por defecto o usar el usuario de la sesión.

Fase 4: Acceso Remoto (Desde el Nodo 3)

Para trabajar desde otra máquina del clúster, lo más sencillo es copiar toda la configuración y software ya preparado.

1. Desde el Nodo 1, copia el directorio de Hive al Nodo 3: `scp -r /opt/hadoop/hive nodo3:/opt/hadoop/`.
2. Conéctate por SSH al Nodo 3.
3. Arranca Beeline en el Nodo 3 y conéctate al servidor del Nodo 1: `!connect jdbc:hive2://nodo1:10000`.
 - Éxito: Si todo es correcto, verás el mensaje de conexión de Apache Hive y podrás ejecutar comandos como `SHOW DATABASES`; desde una máquina totalmente distinta.

Tarea para el alumno

1. Realiza la conexión desde el Nodo 3 y crea una tabla pequeña.
2. Vuelve al Nodo 1 y verifica que la tabla aparece allí.
3. Pregunta de reflexión: ¿Qué sucede si intentas conectarte sin haber cambiado la propiedad `enable.doAs` a `false`?