

Proyecto Final: "Operación Sucesor de Kroos"



Departamento de Estrategia y Big Data - Real Madrid C.F.

1. El Desafío

Tras la retirada de Toni Kroos, el club busca un mediocentro joven capaz de organizar el juego. Debéis procesar dos fuentes de datos masivas para identificar al candidato ideal basándoos en la eficiencia: Rendimiento (FBref) y Finanzas (Transfermarkt).

2. Fase de Ingeniería de Datos (ETL)

Antes de operar en el clúster mediante la interfaz Beeline conectada a HiveServer2, es imperativo realizar un preprocesamiento de los datos con Python. Los alumnos deberán desarrollar un script de limpieza y transformación (ETL) que ejecute las siguientes tareas:

- FBref: Eliminar las cabeceras que se repiten cada 25 filas, corregir el formato de edad (ej. 24-120 → 24) y limpiar comas en los números.
- Transfermarkt: Extraer el nombre del jugador y su valor de mercado en euros (market_value_in_eur).

3. Lógica de Negocio y Requisitos SQL

Debéis construir una consulta en Hive que identifique a los mejores candidatos. El script debe cumplir con los siguientes condicionantes obligatorios:

A. Filtros de Selección (WHERE)

- Estatus Galáctico: Valor de mercado $\geq 50.000.000$ €. El Real Madrid busca jugadores con caché internacional.
- Perfil Organizador: Posición de mediocampista (MF), excluyendo explícitamente a cualquier perfil con rol de delantero (FW).
- La Regla "Adam Wharton": El porcentaje de pase mínimo se fija en un 75%.

Nota: No exijáis un 90% inicial; los jugadores en equipos con menos posesión arriesgan más y sus porcentajes bajan, pero su calidad creativa es altísima.

- Filtro de Élite: Edad ≤ 24 años y más de 900 minutos jugados.

B. Métricas de Impacto y Rentabilidad (SELECT)

Debéis calcular y mostrar en la terminal de Beeline:

1. Impacto Total: Suma de Pases Progresivos + Pases Clave + Creación de Tiro.
2. Ratio de Rentabilidad: Impacto Total / Precio en Millones.
3. Leyendas: Debéis incluir columnas de texto que expliquen las fórmulas para que los resultados sean autoexplicativos (ej. una columna que imprima ' $\leftarrow$ (Impacto / Precio)').

4. Informe de Scouting: Casos de Estudio

jugador	equipo	edad	pct_pase	pases_prog	pases_clav	crea_tiro	precio_millones	impacto_total	info_impacto	impacto_por_millon	info_ratio
Enzo Fernández	Chelsea	23	79.9	212.0	77.0	147.0	85.0	436.0	$\leftarrow$ Suma(Prog+Clav+Crea)	5.129411764705883	$\leftarrow$ (Impacto / Precio
Morgan Gibbs-White	Nott'ham Forest	24	78.3	164.0	51.0	115.0	65.0	330.0	$\leftarrow$ Suma(Prog+Clav+Crea)	5.076923076923077	$\leftarrow$ (Impacto / Precio
Xavi Simons	RB Leipzig	21	78.6	140.0	51.0	108.0	60.0	299.0	$\leftarrow$ Suma(Prog+Clav+Crea)	4.983333333333333	$\leftarrow$ (Impacto / Precio
Manu Koné	Roma	23	91.1	144.0	19.0	67.0	50.0	230.0	$\leftarrow$ Suma(Prog+Clav+Crea)	4.6	$\leftarrow$ (Impacto / Precio
Elliot Anderson	Nott'ham Forest	21	78.3	143.0	37.0	87.0	60.0	267.0	$\leftarrow$ Suma(Prog+Clav+Crea)	4.45	$\leftarrow$ (Impacto / Precio
Pedri	Barcelona	21	87.4	360.0	70.0	165.0	140.0	595.0	$\leftarrow$ Suma(Prog+Clav+Crea)	4.25	$\leftarrow$ (Impacto / Precio
Warren Zaire-Emery	Paris S-G	18	92.8	135.0	18.0	52.0	50.0	205.0	$\leftarrow$ Suma(Prog+Clav+Crea)	4.1	$\leftarrow$ (Impacto / Precio
Pablo Barrios	Atlético Madrid	21	86.0	142.0	26.0	66.0	60.0	234.0	$\leftarrow$ Suma(Prog+Clav+Crea)	3.9	$\leftarrow$ (Impacto / Precio
Vitinha	Paris S-G	24	93.1	224.0	27.0	73.0	90.0	324.0	$\leftarrow$ Suma(Prog+Clav+Crea)	3.6	$\leftarrow$ (Impacto / Precio
Dominik Szoboszlai	Liverpool	23	84.3	131.0	56.0	119.0	85.0	306.0	$\leftarrow$ Suma(Prog+Clav+Crea)	3.6	$\leftarrow$ (Impacto / Precio
Carlos Baleba	Brighton	20	87.4	118.0	21.0	66.0	60.0	205.0	$\leftarrow$ Suma(Prog+Clav+Crea)	3.4166666666666665	$\leftarrow$ (Impacto / Precio
Adam Wharton	Crystal Palace	20	75.6	107.0	26.0	59.0	60.0	192.0	$\leftarrow$ Suma(Prog+Clav+Crea)	3.2	$\leftarrow$ (Impacto / Precio
Sandro Tonali	Newcastle Utd	24	83.7	128.0	28.0	78.0	75.0	234.0	$\leftarrow$ Suma(Prog+Clav+Crea)	3.12	$\leftarrow$ (Impacto / Precio
Moisés Caicedo	Chelsea	22	89.7	215.0	30.0	98.0	110.0	343.0	$\leftarrow$ Suma(Prog+Clav+Crea)	3.118181818181818	$\leftarrow$ (Impacto / Precio
Jeremie Frimpong	Leverkusen	23	76.1	55.0	30.0	66.0	50.0	151.0	$\leftarrow$ Suma(Prog+Clav+Crea)	3.02	$\leftarrow$ (Impacto / Precio
Aleksandar Pavlovic	Bayern Munich	20	93.3	128.0	7.0	30.0	55.0	165.0	$\leftarrow$ Suma(Prog+Clav+Crea)	3.0	$\leftarrow$ (Impacto / Precio
João Neves	Paris S-G	19	91.2	144.0	33.0	68.0	90.0	245.0	$\leftarrow$ Suma(Prog+Clav+Crea)	2.7222222222222223	$\leftarrow$ (Impacto / Precio
Amadou Onana	Aston Villa	22	87.7	75.0	10.0	32.0	50.0	117.0	$\leftarrow$ Suma(Prog+Clav+Crea)	2.34	$\leftarrow$ (Impacto / Precio
Jude Bellingham	Real Madrid	21	86.1	199.0	42.0	105.0	160.0	346.0	$\leftarrow$ Suma(Prog+Clav+Crea)	2.1625	$\leftarrow$ (Impacto / Precio
Eduardo Camavinga	Real Madrid	21	88.3	61.0	11.0	31.0	50.0	103.0	$\leftarrow$ Suma(Prog+Clav+Crea)	2.06	$\leftarrow$ (Impacto / Precio

Una vez obtenido el Top 20 por ratio de rentabilidad, los alumnos deben responder a los siguientes dilemas en su conclusión:

- El Rey del Impacto (Sin límite de dinero): Si el dinero no fuera un problema, el objetivo sería Pedri, quien lidera el impacto total con 595.0.

- La Eficiencia Pura (Sin filtro de caché): Si elimináramos el filtro de los 50M, aparecerían jugadores como Damián Rodríguez con ratios de rentabilidad masivos de 228.0, debido a su bajísimo precio de mercado (500.000 €) frente a su buen rendimiento.
- El Equilibrio (El Fichaje Recomendado): Analizad por qué Enzo Fernández es una opción equilibrada, con un impacto de 436.0 y un ratio de rentabilidad de 5.12.

5. Entregable Final

Cada alumno debe presentar:

1. El código SQL utilizado (sin errores de sintaxis).
2. La tabla de resultados capturada desde la terminal de Beeline.
3. Conclusión Estratégica: Basándote en los datos, ¿ficharías a la "ganga" de algoritmo (ratio máximo), al "galáctico" (impacto máximo) o a un punto intermedio? Justifica tu decisión.