

Práctica de Sistemas Big Data: El Puente Sqoop-Oracle

Manual de Laboratorio Visual: Extracción y Carga Analítica



```
> INITIALIZING DATA BRIDGE...  
STATUS: CONNECTED. STREAMING...  
>
```


¿Por qué aprender una tecnología “Legacy”?

Proyecto Retirado (2021):

Sqoop pasó al Apache Attic, pero la tecnología no desaparece de la noche a la mañana.



La Realidad IT:

Sigue siendo extremadamente útil y omnipresente en el mundo real.



Sectores Clave:

Banca, Seguros y grandes corporaciones mantienen entornos críticos que dependen de Sqoop para conectar RDBMS tradicionales (Oracle, DB2) con Hadoop.



Industry Reality



Apache Attic
(2021)

FLUJO DE DATOS CRÍTICO



Sistemas de
Producción
Críticos

Conexión RDBMS
(Oracle, DB2)

Destino
HDFS/Hadoop

OLTP vs OLAP: El Problema a Resolver




MySQL / Oracle
Transacciones diarias / OLTP

1	Datos estructurados (Tablas).	
2	Escala Vertical (Hardware costoso).	
	Cuello de botella. Consultas analíticas pesadas pueden bloquear el sistema de ventas.	



Hadoop / HDFS
Análisis masivo / OLAP

1	Estructurados, Semi y No estructurados.	
2	Escala Horizontal (Nodos económicos).	
	Permite ejecutar algoritmos pesados (Spark, Hive) sin afectar la base de datos de producción.	



El Flujo de Trabajo Ideal: Oracle gestiona el día a día. Sqoop extrae masivamente hacia Hadoop para análisis. Sqoop exporta los resultados procesados de vuelta a Oracle.

Fase 1: Cimientos (Variables de Entorno)

.bashrc

```
export SQOOP_HOME=/opt/hadoop/sqoop  
export PATH=$PATH:$SQOOP_HOME/bin
```

✓ Configuración base para que Linux reconozca el comando Sqoop.

oracle_env.sh

```
cd /u01/app/oracle/product/11.2.0/xe/bin  
. ./oracle_env.sh
```



¡Peligro de Sintaxis! Fíjate bien en el espacio entre los dos puntos: `'. ./oracle_env.sh'`. Si omites el espacio, el sistema no sabrá dónde están los binarios de Oracle (sqlplus).

Fase 1: Drivers y Desbloqueo de Usuario

El Traductor JDBC

Sqoop necesita un traductor para hablar con Oracle.

```
cp /u01/app/oracle/product/11.2.0/xe/jdbc/lib/ojdbc6.jar /opt/hadoop/sqoop/lib/
```



Nota: Asegúrate de que el usuario hadoop tenga permisos sobre este .jar.

Activación de HR

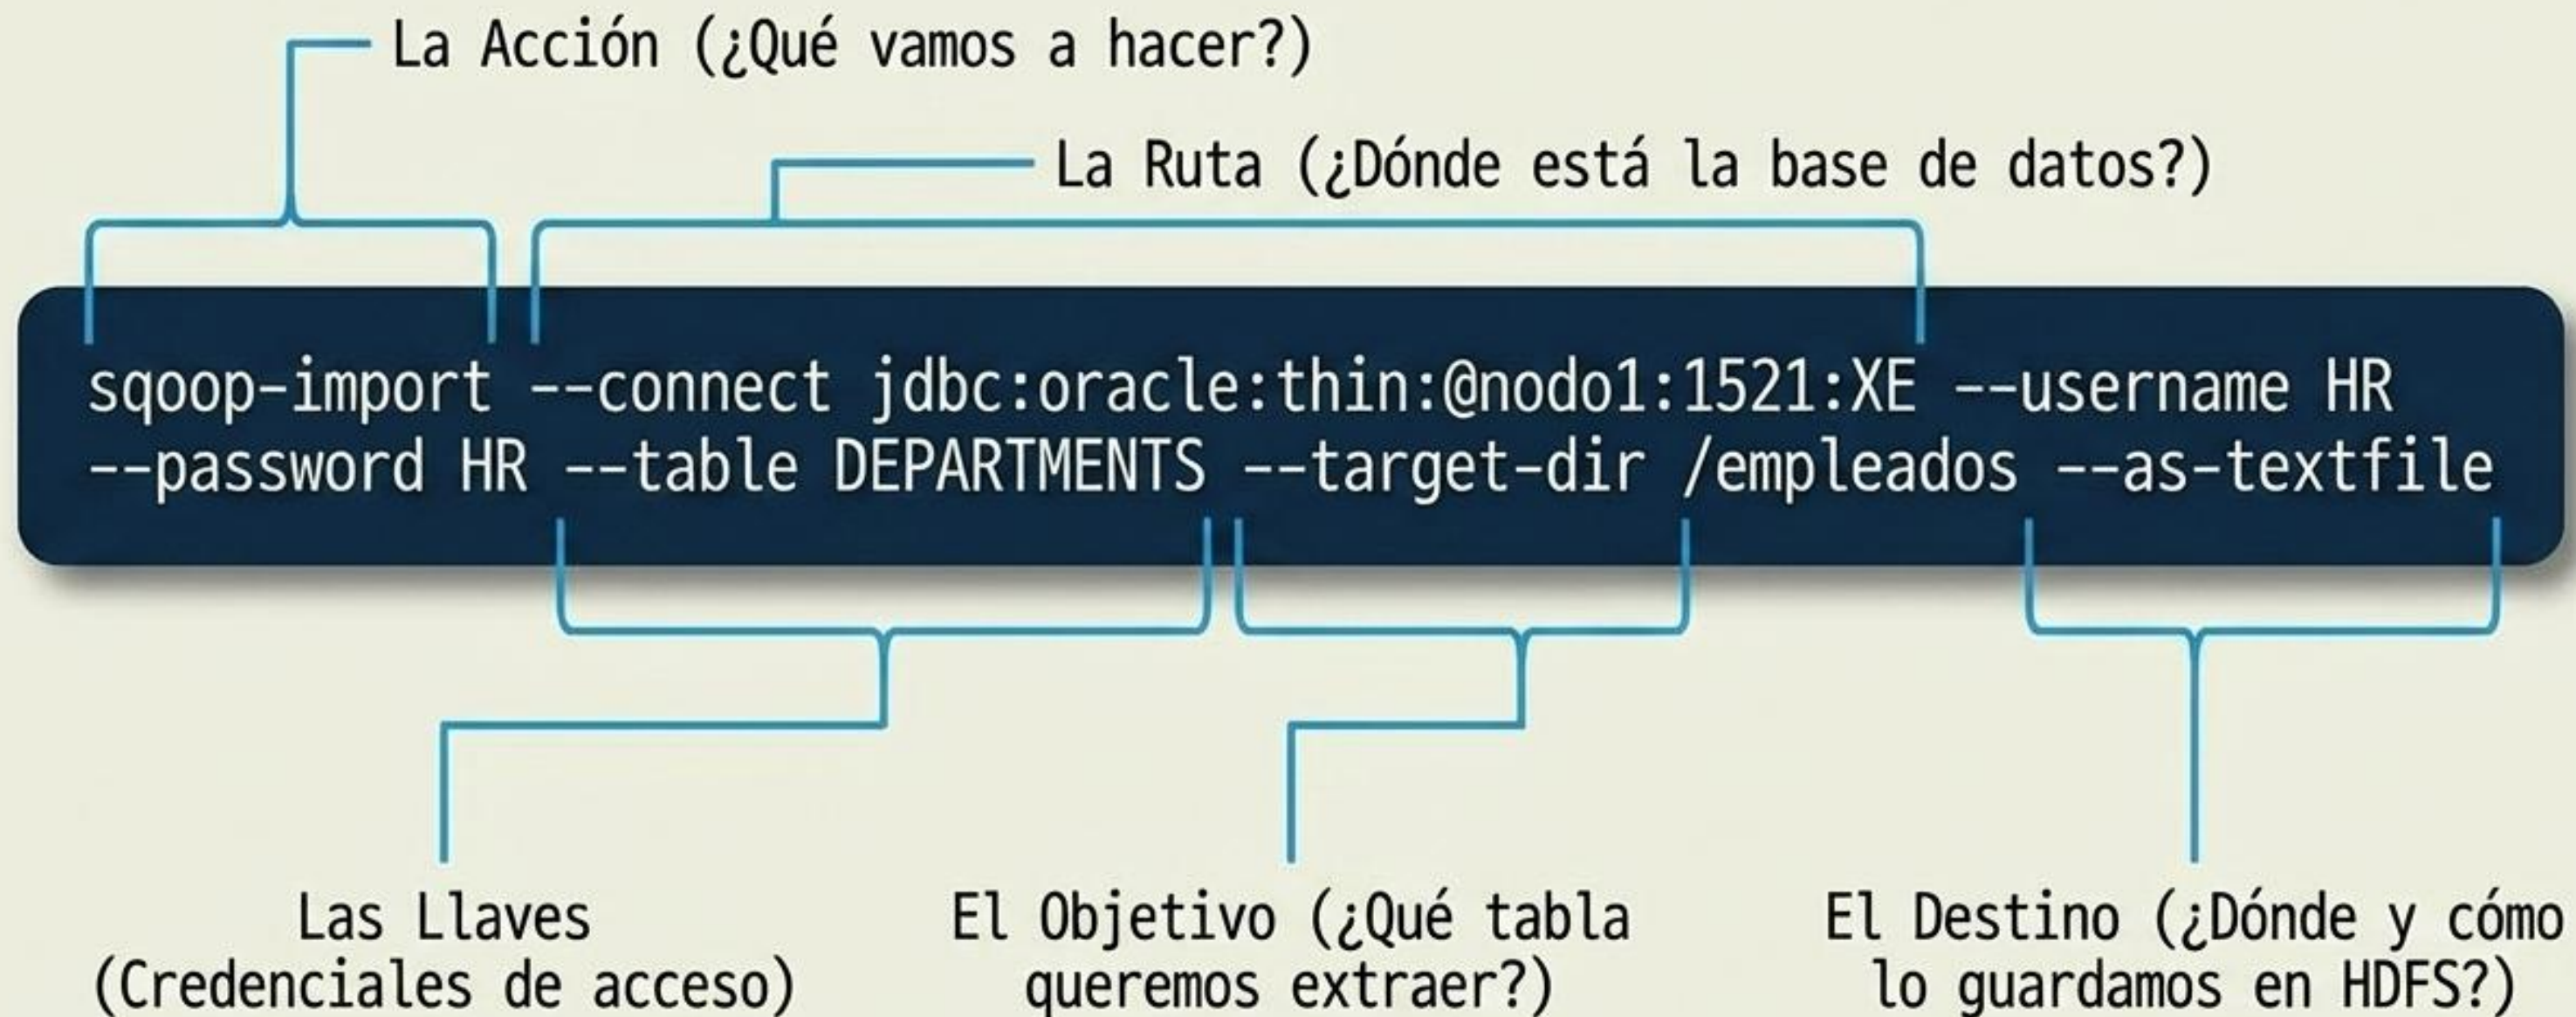
Desbloquear el usuario de ejemplo HR en Oracle.

```
sqlplus / as sysdba  
ALTER USER HR ACCOUNT UNLOCK;  
ALTER USER HR IDENTIFIED BY HR;
```



Usuario HR listo para las prácticas.

La Anatomía del Comando Sqoop



Fase 2: Exploración Previa (Radar de Datos)

Sqoop List-Tables

Verificar que Sqoop tiene visibilidad de las tablas del usuario HR.

```
sqoop list-tables --connect jdbc:oracle:thin:@nodo1:1521:XE --username  
--password HR --password HR
```

SQL*Plus Check

```
sqlplus HR/HR  
select * from departments;
```

10	Administration	200	1700
20	Marketing	201	1800
110	Accounting	205	1700

Conocer la estructura original en Oracle reduce la ansiedad y asegura que sabemos qué esperar en HDFS.

Fase 3: La Importación Básica (Full Table)

Paso 1: El Comando

```
sqoop-import --connect jdbc:oracle:thin:@nodo1:1521:XE --username HR  
--password HR --table DEPARTMENTS --target-dir /empleados -m 1
```

Expert Note: Usamos **-m 1** (un solo Mapper/hilo) para evitar errores de claves primarias en prácticas pequeñas.

Paso 2: Verificación en HDFS

```
hdfs dfs -ls /empleados
```

```
Found 2 items  
-rw-r--r-- 3 hadoop supergroup      0 2018-01-15 02:54 /empleados/_SUCCESS  
-rw-r--r-- 3 hadoop supergroup    165 2018-01-15 02:54 /empleados/part-m-00000
```

```
hdfs dfs -cat /empleados/part-m-00000
```

```
10,Administration,200,1700  
20,Marketing,201,1800  
110,Accounting,205,1700
```


Fase 4: Importación Selectiva (Optimizando la Carga)

Filtro por Columnas

Traer solo lo necesario.

Añadir `--columns`
"DEPARTMENT_ID,DEPARTMENT_NAME"
al comando base.

10,Administration
20,Marketing

(Excluye Manager_ID y Location_ID)

Filtro por Filas (WHERE)

Traer solo registros específicos.

Añadir `--where` "department_id
> 200" al comando base.

210,IT Support
220,NOC
230,IT Helpdesk
(Solo IDs > 200)

Fase 4: Consultas Complejas (Free-form Query)

```
sqoop import --connect jdbc:oracle:thin:@nodo1:1521:XE --username HR  
--password HR \  
--query "SELECT FIRST_NAME, LAST_NAME, DEPARTMENT_NAME, SALARY FROM  
EMPLOYEES A, DEPARTMENTS B WHERE A.DEPARTMENT_ID=B.DEPARTMENT_ID AND  
SALARY > 4000 AND $CONDITIONS" \  
--target-dir /practicas/dept_emple -as-textfile --split-by first_name
```

1. **JOIN Relacional**: La consulta combina EMPLOYEES y DEPARTMENTS directamente en la extracción.



\$CONDITIONS: Es un requisito estrictamente obligatorio de Sqoop al usar **--query**.
Permite a Sqoop inyectar sus propios límites para dividir el trabajo en los mappers.

3. **--split-by**: Obligatorio si usamos más de 1 mapper con una free-form query.

Den, Raphaely, Purchasing, 11000
Alexis, Bull, Shipping, 4100

Fase 5: Exportación (De Hadoop a SQL)


Los datos procesados en Hadoop deben volver a la base de datos para herramientas de BI (PowerBI, Tableau).

Preparar el Terreno (Oracle)



¡Sqoop inserta datos, pero NO crea la estructura de la tabla!

```
CREATE TABLE DPT_EMP (  
  nombre VARCHAR2(20),  
  apellidos VARCHAR2(20),  
  departamento VARCHAR2(20),  
  salario NUMBER  
);
```



El Puente de Retorno (Sqoop)

Se utiliza 'sqoop export' apuntando al directorio de HDFS procesado.



The specific command will follow.

Ejecución de la Exportación

El Comando

```
sqoop export \  
  --connect jdbc:oracle:thin:@nodo1:1521:XE \  
  --username HR --password HR \  
  --table DPT_EMP \  
  --export-dir /practicass/dept_emple \  
  --input-fields-terminated-by ','
```

--export-dir (origen en Hadoop) y **--input-fields-terminated-by ','** (para que Sqoop sepa cómo leer el texto).

Verificación (SQL*Plus)

```
SELECT * FROM DPT_EMP;
```



¡Éxito! Los datos extraídos y procesados en HDFS ahora residen permanentemente en Oracle.

Hoja de Trucos Sqoop (La Navaja Suiza)

Task	Command
Saber la versión	<code>sqoop version</code>
Explorar Tablas	<code>sqoop list-tables --connect [jdbc-url] ...</code>
Traer una tabla (HDFS)	<code>sqoop import --table [nombre]</code>
Filtrar columnas	Añadir <code>--columns "col1,col2"</code>
Filtrar filas	Añadir <code>--where "condicion"</code>
Query Compleja	Usar <code>--query "SELECT... WHERE \\${CONDITIONS}"</code>
Exportar a SQL	<code>sqoop export --table [nombre] --export-dir [ruta_hdfs]</code>



Pro-Tip: Recuerda siempre cargar `'../oracle_env.sh'` y verificar los permisos de `'ojdbc6.jar'` antes de iniciar tu sesión.